

北京市住房价格影响因素分析

——基于特征价格模型的多重回归实证研究

现代回归分析课程论文

2026 年 4 月

摘 要

住房价格的形成机制是城市经济学与房地产研究的核心议题。本研究基于链家（Lianjia）平台 2011 至 2017 年北京市二手房交易数据（约 32 万条记录），在特征价格模型（Hedonic Price Model）的理论框架下，综合运用 OLS 回归、Ridge 回归、LASSO 回归、逐步变量选择及多项式扩展等多种方法，系统考察了影响北京市住房价格的关键因素及其边际效应。研究得到以下主要发现。空间因素（经度、纬度、距市中心距离）是解释房价差异的主导变量，呈现显著的单中心城市空间衰减格局。交易年份对价格具有强预测能力，但其影响呈现明显的非线性特征（2015 年后加速上升），若采用线性趋势设定将产生偏倚风险。房屋属性方面，有无电梯（+7.7%）、临近地铁（+5.8%）、梯户比等变量对价格具有统计显著且经济含义清晰的边际贡献。在模型比较层面，OLS 与多项式组合模型取得了最优预测性能（ $R^2 = 0.829$ ，RMSE=9411 元/m²），但其系数因高阶项引发的严重多重共线性而显著偏离经济直觉，模型的可解释性受到根本性损害。诊断检验表明，数据存在显著异方差（Breusch-Pagan 检验 $p < 0.001$ ）和不同程度的多重共线性（最大 VIF=492.4），经 HC3 稳健标准误修正后仅一个变量的显著性判断发生改变，表明推断结果整体稳健。综合预测精度与经济可解释性，本文推荐以纳入区域和时间双向固定效应的线性主效应模型作为结论支撑。

关键词：特征价格模型；住房价格；多重共线性；LASSO 回归；稳健标准误；固定效应

1 引言

1.1 研究背景

住房兼具消费属性与投资属性，其价格形成机制一直是城市经济学、房地产金融学和应用统计学共同关注的核心议题。北京市作为中国的政治、文化和国际交往中心，其房地产市场具有特殊的典型意义。2011 至 2017 年间，北京二手房市场经历了从温和上涨到加速攀升的转变：安居客等平台数据显示，北京二手房均价从 2011 年的约 2.5 万元/m² 上升至 2017 年的约 6 万元/m²，年均涨幅超过 15%。这一轮房价上涨伴随着快速城镇化、宽松货币政策和房地产市场调控政策（如 2011 年的「京十五条」限购政策、2013 年的「国五条」、2016 年的「9·30 新政」）的交替作用，呈现出典型的政策周期性特征。

在此背景下，准确识别住房价格的影响因素并量化其边际效应，不仅具有学术价值，也对房地产估值、税收评估和住房政策制定具有重要的实践意义。

1.2 文献综述

住房价格研究的经典理论框架是特征价格模型（Hedonic Price Model），该模型由 Rosen（1974）在 Lancaster（1966）的消费者理论基础上系统发展而来。其核心思想是：异质性商品（如住房）的价格由其包含的一系列特征（如面积、位置、房龄等）隐含的价格（特征价格）决定，因此可以通过回归方法估计各特征的隐含价格。这一框架已被广泛应用于住房市场研究（Sirmans et al., 2005; Bourassa et al., 2011）。

在实证方法层面，国内外学者不断拓展特征价格模型的分析工具。在变量选择方面，LASSO 回归（Tibshirani, 1996）通过 L1 惩罚实现自动变量选择，适用于高维特征场景；逐步回归基于信息准则（AIC/BIC）筛选变量，在传统经济计量中仍有广泛应用。在模型诊断方面，Breusch-Pagan 检验（Breusch & Pagan, 1979）和 White 稳健标准误（White, 1980）已成为异方差处理的标准工具；Cook's Distance（Cook, 1977）是识别强影响点的经典方法。

国内住房价格研究方面，郑思齐等（2005）较早采用特征价格模型分析北京住房市场；龙奋杰和郑思齐（2007）系统梳理了特征价格模型在城市研究中的应用；张川川等（2016）利用微观交易数据研究了限购政策对房价的影响。然而，已有研究较少在同一框架内系统比较多种回归方法（正则化、变量选择、多项式扩展）的表现差异，也往往忽视了高缺失率变量的处理偏倚和复杂模型的可解释性损失。本研究旨在弥补上述不足。

1.3 研究框架与贡献

本研究在特征价格模型的理论框架下，基于链家北京 2011–2017 年微观交易数据，构建了从数据预处理、探索性分析、变量选择、模型诊断到多模型比较的完整回归分析流程。本研究的主要贡献体现在以下三个方面。其一，系统比较了六种回归模型在预测精度与经济可解释性之间的权衡，揭示了不同模型在两个维度上的优劣排序及其内在原

因。其二，深入分析了高缺失率变量（DOM 缺失率 50%）的处理偏倚以及多项式模型中因多重共线性引发的系数膨胀问题，为同类研究的方法选择提供了经验证据。其三，在模型评估中不仅关注 R^2 和 RMSE 等预测指标，更强调核心变量的半弹性（semi-elasticity）解释及其经济学含义，力求在预测精度与经济可解释性之间寻求恰当的平衡。

2 数据来源与预处理

2.1 数据来源与说明

本研究使用链家（Lianjia）北京二手房交易数据，时间跨度为 2011 年至 2017 年（含已签约但在链家平台上有记录的存量房源）。原始数据包含约 32 万条交易记录和 26 个变量，涵盖房屋属性（面积、房间数、楼层、朝向等）、交易属性（挂牌天数、关注人数等）、地理位置（经纬度、所在区域）和社区特征（社区均价、电梯、地铁等）四个维度的信息。响应变量为每平方米价格（ $price$ ，元/ m^2 ），经对数变换后作为回归目标。

数据概况如下：原始样本量为 318 621 条，价格均值为 43 562 元/ m^2 ，中位数为 38 752 元/ m^2 ，呈明显右偏分布。时间跨度覆盖 2011 至 2017 年，涉及北京市 15 个行政区划区域。

2.2 变量定义

表 1: 变量定义

变量名	含义	类型	预期方向
$price$	每平方米价格（元/ m^2 ）	响应变量	—
log_price	对数价格（建模目标）	响应变量	—
$dist_center$	距天安门距离（度）	数值	负
Lng, Lat	经度、纬度	数值	待定
$square$	建筑面积（ m^2 ）	数值	待定
$trade_year$	交易年份	数值	正
$elevator$	有无电梯（1/0）	二元虚拟	正
$subway$	临近地铁（1/0）	二元虚拟	正
$ladderRatio$	梯户比	数值	正
DOM	挂牌天数	数值	负
$district_*$	所在区域（15 类）	分类虚拟	各异

注：经对数变换后的 log_price 作为回归目标变量；所有连续型自变量在用于正则化模型前进行了标准化处理。

2.3 数据预处理

数据预处理从原始数据的清洗开始。首先剔除数据泄露变量，包括社区均价（*communityAverage*，与目标变量高度相关会造成前向偏差）、总价（*totalPrice*，总价 = 单价 × 面积，为确定性函数）、社区 ID（*Cid*，超过 6 000 个类别），以及标识符变量（*url*、*id*）。随后进行数据类型修正，*livingRoom*、*drawingRoom* 等列因 Excel 格式问题混入文本，经强制转换为数值类型后，异常值在后续步骤中过滤。极端值过滤方面，剔除价格 < 100 元/m²、面积 < 10m² 或 > 1 000m²、卫生间 > 10 等不合理记录，删除约 300 行。

接下来处理缺失值与异常值。*DOM*（挂牌天数）缺失率达 50%（160 833/318 621），采用中位数填充并添加缺失指示变量（*DOM_missing*）；*constructionTime*（约 6% 缺失）用中位数填充；分类变量（*buildingType*、*elevator* 等）用众数填充。异常值截尾方面，对 *price*、*square*、*ladderRatio*、*followers*、*DOM* 共 5 个变量进行 Winsorize 截尾处理（*price* 和 *square* 为 0.5%，其余为 1%），将极端值替换为分位数值而非直接删除，从而在保留样本量的同时削弱极端值对 OLS 系数的过度影响。

最后进行特征工程。衍生变量构造包括：*property_age*（交易年份-建造年份）、*dist_center*（距天安门经纬度的欧氏距离）、从交易时间提取年度和月度信息并作为分类变量进行独热编码以构建时间固定效应、*log_square* 和 *log_followers*（对数变换）、*floor_level*（楼层类别，分为高/中/低/底/顶/未知）。对数变换目标变量方面，对 *price* 取自然对数作为回归目标，理由有三：其一，缓解右偏——原始价格偏度约 1.31，对数变换后降至约 -0.59，分布更接近对称，有助于满足 OLS 残差近似正态性的假设；其二，稳定方差——房价波动随价格水平增加，对数变换将绝对差异转化为相对差异，有助于缓解异方差；其三，经济学解释——对数线性模型中系数 × 100% 可近似解释为半弹性（semi-elasticity），比原始尺度的边际效应更便于跨变量比较。独热编码方面，对 10 个分类变量进行 one-hot 编码（*drop_first=True*），最终得到 64 个特征（16 个数值型和 48 个虚拟变量）。其中 *trade_year*（2011–2017 年共 7 年）生成 6 个年度虚拟变量（以 2011 年为基期），*trade_month*（1–12 月）生成 11 个月度虚拟变量（以 1 月为基期），二者共同构成时间固定效应。

2.3.1 关于 DOM 变量缺失值的讨论

DOM（挂牌天数）缺失率达 50%，是本数据集中最严重的缺失值问题。根据 Little & Rubin（2019）的分类框架，完全随机缺失（MCAR）的假设难以成立——挂牌天数极短的房源可能因系统记录延迟导致 *DOM* 缺失，更接近于非随机缺失（MNAR）情景。本研究采用中位数填充与缺失指示变量（*DOM_missing*）的复合策略：中位数填充保留了样本量，而 *DOM_missing* 则吸收缺失机制对截距的系统性偏移。

回归结果显示，*DOM_missing* 的系数显著为负（约 -0.028， $p < 0.001$ ），表明 *DOM* 缺失的房源系统性地价格偏低，这一结果与 MNAR 的推论一致（快速成交房源的定价往往更合理，缺失机制与价格水平存在关联）。为检验 *DOM* 处理对核心结论的敏感性，本文建议在模型中分别估计三种设定：（a）包含 *DOM* 与 *DOM_missing*、（b）完全剔除 *DOM* 及其指示变量、（c）仅使用 *DOM_missing*，考察核心变量（*dist_center*、*subway*、

elevator) 的系数是否发生显著改变。若系数稳定, 则表明 *DOM* 缺失对核心结论不构成实质性威胁。

2.3.2 共线性问题的预设考虑

预处理阶段注意到两个主要的共线性来源。其一, *square* 与 *livingRoom* 的皮尔逊相关系数高达 0.72, 表明面积与居室数量之间存在高度重叠的信息。其二, *buildingStructure* 系列虚拟变量在独热编码后呈现类别分布不均衡 (某些结构类型的观测极少), 这将在后文 VIF 诊断中体现为显著的方差膨胀。时间固定效应 (年度和月度虚拟变量) 加入后, 特征空间从 49 个增至 64 个, 但条件数从 7.84×10^6 降至 4.59×10^5 , 说明原模型的病态程度得到了大幅缓解。

2.4 训练-测试集划分与标准化

将数据按 80/20 比例随机划分为训练集 (254 528 条) 和测试集 (63 632 条)。数值型特征经 *StandardScaler* 标准化 (均值为 0、标准差为 1), 虚拟变量不进行标准化以保持类别间的可比性。标准化后的数据专门用于 Ridge 和 LASSO 正则化模型。最终特征空间包含 16 个数值型变量和 48 个虚拟变量 (含时间固定效应), 共计 64 个特征。

3 探索性数据分析

3.1 价格分布与正态性

原始价格 (元/ m^2) 呈明显的右偏分布, 偏度约为 1.31, 存在大量高价尾部。如图 1 所示, 经对数变换后分布接近对称 (偏度约 -0.59), 验证了对数变换作为建模前处理的合理性。然而, Q-Q 图显示在理论分位数 -2 以下和 $+2$ 以上的区间, 实际数据点明显偏离参考线 (呈「S」形或长尾特征), 表明对数正态假设仍不能完全刻画价格分布的厚尾 (fat tails) 特征。这意味着在极高价位和极低价位的房产上, OLS 的正态误差假设被一定程度地违背。这一观察为后续使用 HC3 稳健标准误提供了直观的经验依据。




图 1: 价格分布与对数变换对比

3.2 相关性分析

相关性热力图（图 2）显示，*livingRoom* 与 *square* 之间存在强正相关（ $r = 0.72$ ），验证了前文对多重共线性的预警。在剔除数据泄露变量后，与价格相关性最高的变量依次为经纬度（*Lng*: $r \approx 0.35$, *Lat*: $r \approx 0.25$ ），以及面积和建造年份。区域虚拟变量与价格的相关性呈现清晰的空间梯度，与北京市「中心高、外围低」的房价格局一致。




图 2: 相关性热力图

3.3 地理分布与空间自相关

房价的地理分布呈现典型的单中心城市空间模型（Monocentric City Model）特征。由图 3 可知，散点图中的颜色梯度从市中心（天安门附近）向外围呈辐射状衰减，高价位房源高度集中于东城区、西城区和朝阳区核心地段，远郊区（密云、怀柔、延庆等）价格显著偏低。各区域均价差异明显，朝阳区及中心城区均价最高（约 6-8 万/m²），远郊区域均价较低（约 2-3 万/m²），价差达 3-4 倍。




图 3: 房价地理分布散点图

这种明显的空间聚集性（Spatial Autocorrelation）意味着样本观测之间可能并非独立同分布（i.i.d.）——邻近房源的不可观测特征（如社区环境、邻里质量）往往相似，导致误差项在空间上相关。从空间计量经济学的视角，需要区分两种情形：若真实的数据生成过程为空间误差模型（Spatial Error Model, SEM），即空间相关性来源于误差项的聚类结构，则 OLS 估计量仍然保持一致性和无偏性，但标准误有偏、估计效率降低；若真实过程为空间自回归模型（Spatial Autoregressive Model, SAR），即房价直接受邻近房源价格影响（如参照定价行为），则遗漏空间滞后项将导致遗漏变量偏误，估计量有偏且不一致。本文的 OLS 框架尚未直接处理上述空间依赖性，但在此指出这一区分对于理解空间效应的估计后果具有重要意义。

3.4 价格时间趋势

2011 至 2017 年间，北京二手房均价总体呈上升趋势，但时间路径呈现明显的非线性特征。由图 4 可见，2011 至 2015 年初为平缓上涨阶段（年均涨幅约 5–8%），2015 年下半年至 2017 年进入加速上涨阶段（年均涨幅超过 20%），均价从约 4 万元/m² 跃升至约 7 万元/m²。这一趋势与同期的货币政策宽松（2015 年多次降息降准）、房地产去库存政策以及 2016 年「9·30 新政」前的市场预期升温密切相关。




图 4: 分年度价格趋势

这一发现具有重要的计量含义。在早期版本的模型中， $trade_year$ 被作为连续线性变量纳入回归，实质上施加了「年度价格增幅恒定」的约束，这显然不符合数据特征。在本文的最终模型设定中， $trade_year$ 已被替换为年份虚拟变量（即时间固定效应，同时纳入月度虚拟变量控制季节性），让数据自行估计每年的基准价格水平。后文表 3 显示，年份虚拟变量的系数从 2012 年的约 +0.15 逐渐递增至 2017 年的约 +1.15，年与年之间的增幅并不相等——2015 年后的系数跳跃明显更大，与 EDA 观察到的趋势转折完全一致。这验证了时间固定效应设定的合理性。

4 模型设定与变量选择

4.1 基准回归模型

本研究在特征价格模型框架下，设定包含时间和区域双向固定效应的半对数回归方程作为基准模型：

$$\log(\text{Price}_{it}) = \beta_0 + \mathbf{X}'_{it}\boldsymbol{\beta} + \gamma_t + \delta_k + \varepsilon_{it} \quad (1)$$

其中 $\log(\text{Price}_{it})$ 为第 i 条交易在第 t 期的对数价格； $\mathbf{X}_{it}$ 包含连续型房屋和区位特征（ $dist_center$ 、 Lat 、 Lng 、 $square$ 等）； γ_t 为时间固定效应，由年度虚拟变量（ $trade_year_2012$ 至 $trade_year_2017$ ，以 2011 年为基期）和月度虚拟变量（ $trade_month_2$ 至 $trade_month_12$ ，以 1 月为基期）共同实现； δ_k 为区域固定效应。

该设定的关键优势在于不施加「年度价格增幅恒定」的线性约束，允许数据自行估计每年的基准价格水平。第三节的探索性分析已表明 2011–2017 年房价趋势呈明显非线性特征——2015 年前平缓上涨、2015 年后加速攀升，因此 γ_t 的灵活设定远优于线性趋势变量。月度虚拟变量则进一步控制季节性波动（如年初和年末的交易量差异）。

为探索空间和房屋属性变量的非线性边际效应，对 5 个关键连续变量构造多项式扩展模型：

$$\log(\text{Price}) = \beta_0 + \mathbf{X}'\boldsymbol{\beta} + \mathbf{Z}'\boldsymbol{\gamma} + \text{vec}(\mathbf{Z} \otimes \mathbf{Z})'\boldsymbol{\theta} + \varepsilon \quad (2)$$

其中 $\mathbf{Z}$ 为 5 个关键连续变量 ($dist_center$ 、 Lat 、 Lng 、 $ladderRatio$ 、 DOM) 组成的向量。经度和纬度参与扩展以捕捉空间曲面的弯曲，梯户比和挂牌天数参与扩展以允许边际效应递减。 $trade_year$ 不再参与多项式扩展，因为时间固定效应已通过年度虚拟变量灵活捕捉了非线性的时间趋势。 $\mathbf{Z} \otimes \mathbf{Z}$ 包含所有二次项和两两交互项。该设定允许关键变量存在非线性边际效应，但代价是引入严重的多重共线性（见第五章）。上述线性基准模型（带有时间-区域双向固定效应）是本文进行经济推断的主要依据，而多项式模型主要用于对比和展示非线性扩展的代价。

4.2 变量选择的共识策略

为在高维特征空间（64 个特征，含时间固定效应）中识别最重要的预测变量，本研究综合运用三种方法：基于 AIC 的向前选择、基于 AIC 的向后剔除，以及 LASSO 正则化路径。采用共识策略（至少被两种方法选中）确定最终变量集，以增强变量选择的稳健性。

变量选择结果如下：全部 64 个特征中，29 个被三种方法一致选中（高度稳健），30 个被两种方法选中（中度稳健），4 个仅被一种方法选中，1 个未被任何方法选中。最终共识变量集包含 59 个变量。三种方法的一致性程度较高。被一致选中的重要变量包括经纬度 (Lng 、 Lat)、距市中心距离 ($dist_center$)、梯户比 ($ladderRatio$)、有无电梯 ($elevator$)、临近地铁 ($subway$)、建筑面积对数 (log_square) 及大部分区域虚拟变量。值得注意的是，年份虚拟变量 ($trade_year_2012$ 至 $trade_year_2017$) 和多数月份虚拟变量同样被全票选中，验证了时间固定效应纳入模型的必要性。

4.2.1 LASSO 正则化与惩罚力度问题




图 5: LASSO 正则化路径

LASSO 交叉验证选择的最优惩罚参数为 $\alpha = 0.0001$ ，恰好位于搜索网格 $[10^{-4}, 10^0]$ 的下界。图 5 显示，模型在此参数下保留了 60/64 个非零系数（仅 4 个系数被压缩至零），惩罚力度极为微弱。将搜索网格向下扩展至 10^{-5} 后，最优 α 仍然落在新的下界，表明这一结果并非网格设定问题所导致。

这一现象的数据解释是：64 个候选特征中绝大多数都与房价存在统计上显著的关联，强预测信号在特征空间中广泛分布，LASSO 无法通过 L1 惩罚将有效信号压缩为零。这与「真实模型稀疏」的隐含前提相悖——住房价格通常受众多微效因素共同影响。因此 LASSO 在本应用中本质上退化为了普通 OLS，这也解释了为何在后文的模型比较中二者的预测表现几乎完全一致（ R^2 均为 0.818）。

5 模型诊断

基于全变量 OLS 模型（子样本 20 000 行），对经典线性回归的假设条件进行系统检验。

5.1 诊断检验结果

表 2: 模型诊断结果汇总

检验项目	结果
VIF > 10 变量数	9 个（ <i>buildingStructure</i> 系列、 <i>square</i> 、 <i>log_square</i> 、 <i>trade_year_2016/2017</i> ）
最大 VIF（不含常数项）	492.4（ <i>buildingStructure_6</i> ）
条件数（Cond. No.）	4.59×10^5 （较原模型 7.84×10^6 大幅改善）
Breusch-Pagan 检验	LM=957.6, $p = 1.8 \times 10^{-159} \rightarrow$ 拒绝同方差
Goldfeld-Quandt 检验	$F = 0.979$, $p = 0.857 \rightarrow$ 不拒绝同方差
Durbin-Watson 统计量	1.966 $\rightarrow$ 无自相关
Cook's D 异常点比例	4.74%（947/20 000）超过阈值
HC3 下显著性改变量	1 个变量（ <i>five YearsProperty_1.0</i> ）

5.2 多重共线性讨论

表 2 报告了 VIF 诊断结果。*buildingStructure_6*（VIF=492.4）和 *buildingStructure_2*（VIF=468.8）存在严重的多重共线性。这与 *buildingStructure* 变量的类别分布密切相关：某些结构类别（如钢结构）的占比极低，导致相应的虚拟变量与其他结构类别之间呈现近乎完全的线性关系。此外，*square*（22.4）和 *log_square*（20.9）之间的高度相关性也反映了面积变量在对数-线性变换后的共线性问题。部分年份虚拟变量（*trade_year_2016*、2015、2017）的 VIF 超过 10，这是以 2011 年为高基期、多年度同时纳入模型时的自然结果。

对于以 OLS 为基础的统计论文，9 个 $VIF > 10$ 的变量虽然不影响模型的整体预测能力，但会膨胀个体系数的标准误、降低估计精度。值得注意的是，加入时间固定效应后条件数从 7.84×10^6 降至 4.59×10^5 （降幅约 94%），这是因为原模型中的 *trade_year* 连续变量与其平方项之间存在大量共线性，被年份虚拟变量替代后这一来源得到消除。在 OLS 与多项式组合模型中，多重共线性问题因高阶项的加入而显著加剧，详见第 6.3 节。

5.3 异方差与残差分析

Breusch-Pagan 检验在 1% 水平上显著拒绝同方差假设 ($p = 1.8 \times 10^{-159}$)，而 Goldfeld-Quandt 检验未能检测到异方差 ($p = 0.857$)。两个检验结论的不一致根源在于检验功效和敏感性的差异：BP 检验对一般形式的异方差均敏感，而 GQ 检验仅对排序后单调变化的方差敏感。图 6 中的残差诊断图显示，当拟合值增大时残差幅度呈现扩散趋势，这一「漏斗状」模式支持 BP 检验的结论，即样本中存在不可忽略的异方差。




图 6: 残差诊断图（左上：残差 vs 拟合值；右上：尺度-位置图；左下：Q-Q 图）

5.4 稳健标准误

采用 HC3 稳健标准误对 OLS 系数进行校正。结果表明：HC3 校正后仅一个变量 (*fiveYearsProperty_1.0*) 的显著性判断发生改变 (从 $p = 0.048$ 变为 $p = 0.053$, 略超 5% 阈值)。这一结果优于原模型 (3 个变量显著性改变)，说明加入时间固定效应后异方差对推断的干扰进一步减弱。因此，HC3 稳健标准误的使用主要作为学术严谨性的必要组成部分，而非因为实质性改变了结论。

截面数据的异方差在真实世界中是常态而非异常。本研究从事前和事后两个层面确保了推断的可靠性。事前，半对数设定将绝对差异转化为相对差异，从数据变换的根源上缓解了方差随价格水平递增的趋势；事后，HC3 稳健协方差矩阵的修正进一步消除了异方差对标准误估计的干扰。因此，即便 Breusch-Pagan 检验明确拒绝了同方差假设，核心变量边际效应的推断结果仍然是稳健且可靠的。

6 模型比较与结果解释

本研究比较了六种回归模型在测试集上的表现，这六种模型涵盖了从简洁可解释到灵活复杂的光谱：OLS (全变量，含时间固定效应)、Ridge 回归 (交叉验证选 λ)、LASSO 回归 (交叉验证选 λ)、OLS (共识筛选变量)、OLS 与交互项组合 (5 个关键变量的两

两交互)、OLS 与多项式组合 (5 个关键变量的二次项与交互项, 共 79 个特征)。其中关键连续变量从 6 个变为 5 个 (*trade_year* 因转为虚拟变量不再参与多项式扩展)。

6.1 预测表现比较

各模型在测试集上的表现汇总于表 3。

表 3: 测试集模型表现比较

模型	R^2	RMSE (元/m ²)	MAE (元/m ²)	AIC
OLS + 多项式	0.8294	9 411	6 471	-207 770
OLS + 交互项	0.8218	9 621	6 631	-205 038
OLS (全变量)	0.8185	9 696	6 703	-203 859
Ridge (CV)	0.8185	9 696	6 703	—
OLS (筛选变量)	0.8184	9 695	6 703	-203 867
LASSO (CV)	0.8180	9 710	6 713	—

OLS 与多项式组合模型在预测指标上表现最佳 ($R^2 = 0.829$, RMSE=9 411 元/m²), 较基准 OLS ($R^2 = 0.818$, RMSE=9 696 元/m²) 提升约 1.1 个百分点, RMSE 降低约 285 元/m²。五折交叉验证结果与测试集一致 ($CV R^2 = 0.8295 \pm 0.002$), 排除了过拟合的可能。与旧版本模型 (*trade_year* 为连续变量) 相比, 当前基准 OLS 的 R^2 从 0.786 提升至 0.818 (+3.2 个百分点), RMSE 从 10 428 降至 9 696 (降幅 7.0%), 充分说明时间固定效应设定的有效性。然而, OLS 与多项式模型之间的 R^2 差距也从原来的 1.9 个百分点缩窄至 1.1 个百分点——这是因为时间固定效应已经捕捉了部分原来多项式模型才能拟合的非线性时间趋势。

6.2 核心变量的边际效应解释

在评估模型时, 本研究不仅关注预测精度, 更重视核心变量的边际效应 (Marginal Effects) 的经济学含义。以下基于共识变量 OLS 模型 (兼顾可解释性和变量选择的稳健性) 对关键变量进行半弹性解释。在对数-线性模型中, 连续变量 X 的系数 β 的精确解释为: X 增加一个单位时, 响应变量变化 $100 \times (e^\beta - 1)\%$ 。当 $|\beta|$ 较小时 (如 $|\beta| < 0.1$), $\beta \times 100\%$ 可作为近似。

首先考察空间因素的影响。距市中心距离 (*dist_center*) 的系数为 -2.681 ($p < 0.001$), 意味着距天安门每增加 0.01 度 (约 1.1 公里), 房价下降约 $e^{-2.681 \times 0.01} - 1 \approx -2.65\%$ 。以 2017 年北京二手房均价约 6 万元/m² 计算, 每远离市中心 1 公里, 单价下降约 1 590 元。这一效应在统计和经济意义上均高度显著, 印证了北京作为单中心城市的空间结构特征。

房屋建筑特征方面, 有无电梯 (*elevator*) 的系数为 0.074 ($p < 0.001$), 有电梯的房源比无电梯房源价格高出 $e^{0.074} - 1 \approx 7.7\%$ 。对于均价 6 万元/m² 的住宅, 这一溢价约

为 4620 元/m²，折合到一套 80m² 的住房约为 37 万元。梯户比 (*ladderRatio*) 的系数为 0.167 ($p < 0.001$)，梯户比每增加 0.1 (如从 1 梯 4 户变为 1 梯 3 户)，房价上升约 $e^{0.167 \times 0.1} - 1 \approx 1.68\%$ ，反映了居住舒适度对房价的资本化效应。

交通便利性方面，临近地铁 (*subway*) 的系数为 0.056 ($p < 0.001$)，临近地铁的房源溢价约为 $e^{0.056} - 1 \approx 5.8\%$ (约 3480 元/m²)，体现了轨道交通对住房价值的资本化效应。值得注意的是，这一效应在远郊区域可能更为显著，因为远郊居民对轨道交通的依赖度高于中心城区。




图 7: 最佳模型系数图 (OLS+ 多项式, 前 15 名)

6.3 多项式模型的系数膨胀问题

图 7 展示了 OLS 与多项式组合模型中系数绝对值最大的 15 个变量。部分区域虚拟变量的系数绝对值达到 200 至 800 的量级。由于响应变量为 $\log(\text{price})$ ，这意味着某区域的边际效应为 e^{200} 至 e^{800} 倍，在经济意义上不再具有合理的解释力。

这一现象的根源在于：多项式扩展将 5 个关键变量 (*dist_center*、*Lat*、*Lng*、*ladderRatio*、*DOM*) 扩展为 20 个二次项和交互项。这些高阶项与已有的区域虚拟变量 (*district_**) 之间存在严重的多重共线性——区域本身就是地理空间的离散化表示，而经纬度的多项式组合是对同一空间的连续函数逼近。二者高度相关导致正规方程 ($\mathbf{X}'\mathbf{X}$) 近乎奇异，条件数急剧恶化，回归系数在理论上趋向无穷大，呈现出 ± 200 至 ± 800 的反常值。值得注意的是，虽然 *trade_year* 已转为虚拟变量不再参与多项式扩展，但 *dist_center* 与 *Lat/Lng* 之间的空间共线性仍然足以引发矩阵病态。

这一发现揭示了一个重要的方法论教训：线性回归模型在引入高阶多项式项后，虽然预测精度有所提升，但其核心优势——系数可直接解释为边际效应——受到了根本性损害。当研究目标是经济推断 (*inference*) 而非预测 (*prediction*) 时，简洁的主效应线性模型在设计合理的固定效应设定下，通常是更为可靠的选择。

6.4 时间趋势的进一步讨论

在共识变量 OLS 模型中,年份虚拟变量的系数呈现清晰的递增模式: $trade_year_2012$ (+0.15)、 $trade_year_2013$ (+0.48)、 $trade_year_2014$ (+0.49)、 $trade_year_2015$ (+0.54)、 $trade_year_2016$ (+0.83)、 $trade_year_2017$ (+1.15),以 2011 年为基期。这一序列的特征在于:2013 年较 2012 年有大幅跳跃 (+0.33),而 2013–2015 年间增幅相对平缓(年增约 0.03–0.05),2015 年后再次加速(2016 年 +0.29,2017 年 +0.32)。该模式与探索性数据分析中观察到的「2011–2015 年初平缓上涨、2015 下半年后加速攀升」完全吻合。

在旧版模型中 $trade_year$ 被作为连续线性变量(系数 0.180),等效于为所有年份施加了「年增幅约 19.7%」的单一系数,这必然低估 2015 年后的涨幅并高估 2011–2014 年的涨幅。时间固定效应解决了这一问题,同时消解了旧版模型中需要依赖 $trade_year^2$ 项来部分捕捉非线性趋势的妥协。月度虚拟变量的系数也从 2 月 (+0.046) 逐步递增至 12 月 (+0.190),反映了一年内的季节性价格上升趋势。

7 结论

7.1 主要发现

本研究通过特征价格模型框架和多种回归方法,对北京市住房价格的影响因素进行了系统的实证分析,得到以下几方面主要发现。

第一,空间因素是解释房价差异的主导变量。距市中心距离、经纬度和区域虚拟变量具有最强的解释力,北京市呈现单中心城市空间结构,距市中心每增加 1 公里,房价下降约 2.7%,梯度效应显著。第二,时间因素具有非线性影响。年份虚拟变量系数从 2012 年的 +0.15 逐步递增至 2017 年的 +1.15,验证了 2015 年前后房价结构性加速的特征;时间固定效应的设定显著优于连续的 $trade_year$ 线性变量。第三,房屋特征对价格具有独立的贡献。电梯 (+7.7%)、地铁 (+5.8%)、梯户比等因素的边际效应在统计和经济意义上均高度显著。

在方法论层面,研究揭示了预测精度与经济可解释性之间的权衡关系。OLS 与多项式组合模型取得了最高预测精度 ($R^2 = 0.829$, RMSE=9 411 元/ m^2),但高阶项导致系数膨胀至无法经济解释的程度。当研究侧重于经济推断时,纳入时间和区域双向固定效应的线性主效应模型 ($R^2 = 0.818$, RMSE=9 696 元/ m^2) 是更可靠的选择。此外,LASSO 在本应用场景中未能实现有效的变量选择,因为 64 个特征中多数与房价存在真实关联,稀疏性假设不成立,最优 α 趋近于零,模型退化为 OLS。诊断方面,HC3 稳健标准误的采用仅改变了一个变量的显著性判断,条件数从 7.84×10^6 降至 4.59×10^5 ,但 $buildingStructure$ 类别的 VIF 仍高达 490 以上,表明共线性问题仍需关注。

7.2 研究局限与未来方向

本研究存在若干局限，需要在后续研究中加以改进。数据方面，样本来源仅为链家平台，虽然链家在北京二手房市场占有率较高，但仍可能存在平台选择偏误，研究结论未必能完全推广至北京二手房整体市场。同时，*DOM* 变量 50% 的缺失率对估计一致性构成了实质性威胁，当前采用的中位数填充方法可能导致系数衰减偏倚，更严格的学术研究应采用多重插补或直接剔除该变量。

模型设定方面存在以下不足。其一，模型未纳入宏观经济变量（利率、M2 增速、限购政策虚拟变量等），年份虚拟变量的系数可能混杂了时间趋势与宏观冲击的双重效应——这是线性固定效应模型的内在局限，无法区分「时间」本身和「随时间变化的其他因素」。其二，模型存在不可忽视的内生性问题。遗漏变量方面，数据中未包含「学区」这一公认的强影响因子（在北京，学区房溢价可达 20%–50%），遗漏该变量将导致 OLS 系数估计产生偏误，尤其是区域虚拟变量和距市中心距离的系数可能被高估。反向因果方面，以地铁变量为例，政府倾向于在房价高、人口密集的区域优先规划地铁线路，这意味着地铁与房价之间可能存在双向因果关系，导致 OLS 估计的 +5.8% 溢价并非纯粹的因果效应。由于本研究未采用工具变量（IV）、双重差分（DID）或断点回归（RDD）等因果推断方法，上述结果应解释为条件相关性（conditional correlation）而非因果关系。后续研究可考虑利用地铁规划的准自然实验或构造工具变量来处理这一内生性来源。其三，基于 OLS 的分析框架未处理空间自相关。空间自相关对 OLS 估计的影响取决于其具体形式：若为空间误差（SEM），OLS 系数仍保持一致但标准误需校正；若为空间滞后（SAR），则需采用工具变量或空间两阶段最小二乘法加以识别。后续研究应首先通过 Moran's I 检验判断空间自相关的具体形式，再选择对应的空间计量模型。

技术层面，条件数 4.59×10^5 表明设计矩阵仍存在一定病态性。虽然较原模型 (7.84×10^6) 已有大幅改善，但 *buildingStructure* 虚拟变量和多项式模型的高阶项仍可导致矩阵接近奇异。后续研究可考虑主成分回归（PCR）或对 *buildingStructure* 类别进行合并。特征工程方面，可以将 *livingRoom* 和 *square* 的组合替代为单位居室面积 (*square/livingRoom*)，并对 *buildingStructure* 类别进行合并以减少虚拟变量的稀疏性，从而在降低模型复杂度的同时保持预测精度。

参考文献

- [1] Rosen S. Hedonic prices and implicit markets: product differentiation in pure competition[J]. *Journal of Political Economy*, 1974, 82(1): 34–55.
- [2] Lancaster K J. A new approach to consumer theory[J]. *Journal of Political Economy*, 1966, 74(2): 132–157.
- [3] Tibshirani R. Regression shrinkage and selection via the lasso[J]. *Journal of the Royal Statistical Society: Series B*, 1996, 58(1): 267–288.

- [4] Breusch T S, Pagan A R. A simple test for heteroscedasticity and random coefficient variation[J]. *Econometrica*, 1979, 47(5): 1287–1294.
- [5] White H. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity[J]. *Econometrica*, 1980, 48(4): 817–838.
- [6] Cook R D. Detection of influential observation in linear regression[J]. *Technometrics*, 1977, 19(1): 15–18.
- [7] Little R J A, Rubin D B. *Statistical Analysis with Missing Data*[M]. 3rd ed. New York: Wiley, 2019.
- [8] Sirmans S G, Macpherson D A, Zietz E N. The composition of hedonic pricing models[J]. *Journal of Real Estate Literature*, 2005, 13(1): 1–44.
- [9] Bourassa S C, Cantoni E, Hoesli M. Robust hedonic price models[J]. *Real Estate Economics*, 2011, 39(3): 447–474.
- [10] 郑思齐, 刘洪玉. 住房需求的收入弹性: 理论与实证 [J]. *中国房地产研究*, 2005(2): 1–15.
- [11] 龙奋杰, 郑思齐. 城市住房价格的空间特征与影响因素分析 [J]. *城市规划*, 2007(4): 23–28.
- [12] 张川川, 贾坤, 杨汝岱. 住房限购政策对房价的影响——基于北京市微观交易数据的实证研究 [J]. *经济学 (季刊)*, 2016.