

北京市住房价格影响因素分析

——基于特征价格模型的多重回归实证研究

摘 要

本研究基于链家平台 2011 至 2017 年北京市二手房交易数据，在特征价格模型框架下，综合运用 OLS 回归、Ridge 回归、LASSO 回归及多项式扩展等方法，系统考察了影响北京市住房价格的关键因素。空间因素（距市中心距离、经纬度、区域虚拟变量）是解释房价差异的主导变量，呈现显著的单中心城市空间衰减格局。交易年份对价格具有强预测能力且呈明显非线性，房屋属性（电梯、地铁、梯户比）的边际效应在统计和经济意义上均显著。在模型比较层面，多项式模型预测精度最高（ $R^2 = 0.829$ ），但高阶项引发的多重共线性严重损害了系数的可解释性。综合预测精度与经济可解释性，本文推荐以纳入区域和时间双向固定效应的线性主效应模型作为结论支撑。

关键词：特征价格模型；住房价格；多重共线性；LASSO 回归；稳健标准误；固定效应

1. 引言

住房兼具消费与投资属性，其价格形成机制是城市经济学的核心议题。北京市作为中国政治文化中心，2011 至 2017 年间二手房均价从约 2.5 万元/m² 上升至约 6 万元/m²。这一时期伴随快速城镇化、宽松货币政策和调控政策（如「京十五条」「9·30 新政」等）的交替作用，呈现出典型的政策周期性特征。

特征价格模型是住房价格研究的经典框架，由 Rosen[1] 在 Lancaster[2] 消费者理论基础之上系统发展而来。该模型的核心思想是：异质性商品的价格由其特征隐含价格决定。在实证方法层面，LASSO 回归 [3] 通过 L1 惩罚实现自动变量选择，Breusch-Pagan 检验 [4] 和 White 稳健标准误 [5] 已成为异方差处理的标准工具。国内方面，郑思齐等 [7] 较早将特征价格模型应用于北京住房市场。然而，已有研究较少在同一框架内系统比较多种回归方法的表现差异，也往往忽视了高缺失率变量的处理偏倚和复杂模型的可解释性损失。

本研究基于链家北京 2011–2017 年微观交易数据，构建了从数据预处理、探索性分析、变量选择、模型诊断到多模型比较的完整回归分析流程。主要贡献体现在三个方面。第一，系统比较了六种回归模型在预测精度与经济可解释性之间的权衡。第二，分析了多项式模型因多重共线性引发的系数膨胀问题。第三，强调核心变量的半弹性解释，在预测精度与可解释性之间寻求恰当的平衡。

2. 数据来源与预处理

2.1 数据来源与变量定义

本研究使用链家北京二手房交易数据（2011–2017 年），原始数据包含 318 621 条交易记录和 26 个变量。表 1 列出了主要变量及其含义。

表 1: 变量定义

变量名	含义	类型
<i>price</i>	每平方米价格（元/m ² ）	响应变量
<i>log_price</i>	对数价格（建模目标）	响应变量
<i>dist_center</i>	距天安门距离（度）	数值
<i>Lng, Lat</i>	经度、纬度	数值
<i>square</i>	建筑面积（m ² ）	数值
<i>trade_year</i>	交易年份	数值
<i>elevator</i>	有无电梯（1/0）	二元虚拟
<i>subway</i>	临近地铁（1/0）	二元虚拟
<i>ladderRatio</i>	梯户比	数值
<i>DOM</i>	挂牌天数	数值
<i>district_*</i>	所在区域（15 类）	分类虚拟

2.2 数据预处理

数据预处理包括四个步骤。第一，剔除数据泄露变量（社区均价、总价等）和标识符变量，修正数据类型错误。第二，过滤极端值（价格 <100 元/m²、面积 >1000m² 等），共删除约 300 行。第三，处理缺失值：*DOM* 缺失率达 50%，采用中位数填充并添加缺失指示变量 *DOM_missing*；*constructionTime* 缺失约 6%，用中位数填充。第四，特征工程：对 *price* 取自然对数作为回归目标（偏度从 1.31 降至 -0.59），对 10 个分类变量进行独热编码，生成时间固定效应（6 个年度虚拟变量 +11 个月度虚拟变量）。最终特征空间包含 16 个数值型变量和 48 个虚拟变量，共计 64 个特征。

2.3 训练-测试集划分

将数据按 80/20 比例随机划分为训练集（254 528 条）和测试集（63 632 条）。数值型特征经标准化处理后用于 Ridge 和 LASSO 正则化模型，虚拟变量不进行标准化。

3. 探索性数据分析

图 1 展示了价格分布与对数变换效果。原始价格偏度为 1.31，呈明显右偏；对数变换后偏度降至 -0.59 ，分布接近对称，验证了对数变换的合理性。Q-Q 图尾部的偏离表明对数正态假设仍有不足，为后文使用 HC3 稳健标准误提供了依据。




图 1: 价格分布与对数变换对比

图 2 为相关性热力图。*livingRoom* 与 *square* 相关系数达 0.72，存在多重共线性隐患。剔除数据泄露变量后，与价格相关性最高的变量依次为经纬度、面积和建造年份。




图 2: 相关性热力图

图 3 显示房价地理分布呈现典型的单中心空间结构：颜色梯度从市中心向外围辐射状衰减，东城、西城和朝阳核心区价格最高，远郊区显著偏低，价差达三到四倍。




图 3: 房价地理分布散点图

图 4 为分年度价格趋势。2011–2015 年初为平缓上涨阶段，2015 年下半年后加速攀

升，均价从约 4 万元/m² 跃升至约 7 万元/m²。这一非线性趋势表明，将 *trade_year* 作为连续变量会施加「年增幅恒定」的不当约束。因此，本文采用年份虚拟变量替代，让数据自行估计每年的基准价格水平。




图 4: 分年度价格趋势

4. 模型设定与变量选择

4.1 基准回归模型

本研究在特征价格模型框架下，设定包含时间和区域双向固定效应的半对数回归方程作为基准模型：

$$\log(\text{Price}_{it}) = \beta_0 + \mathbf{X}'_{it}\boldsymbol{\beta} + \gamma_t + \delta_k + \varepsilon_{it} \quad (1)$$

其中 $\log(\text{Price}_{it})$ 为第 i 条交易在第 t 期的对数价格， $\mathbf{X}_{it}$ 包含 *dist_center*（距市中心距离）、*Lat*（纬度）、*Lng*（经度）、*square*（建筑面积）、*ladderRatio*（梯户比）、*DOM*（挂牌天数）等连续型房屋和区位特征。 γ_t 为时间固定效应，由年度虚拟变量（*trade_year_2012* 至 *trade_year_2017*，以 2011 年为基期）和月度虚拟变量（*trade_month_2* 至 *trade_month_12*，以 1 月为基期）共同实现。 δ_k 为区域固定效应。

该设定的关键优势在于不施加年度价格增幅恒定的线性约束，允许数据自行估计每年的基准价格水平。第三节的探索性分析已表明 2011–2017 年房价趋势呈明显非线性特征，2015 年前平缓上涨、2015 年后加速攀升，因此 γ_t 的灵活设定远优于线性趋势变量。月度虚拟变量则进一步控制季节性波动。

为探索空间和房屋属性变量的非线性边际效应，对 5 个关键连续变量构造多项式扩展模型：

$$\log(\text{Price}) = \beta_0 + \mathbf{X}'\boldsymbol{\beta} + \mathbf{Z}'\boldsymbol{\gamma} + \text{vec}(\mathbf{Z} \otimes \mathbf{Z})'\boldsymbol{\theta} + \varepsilon \quad (2)$$

其中 $\mathbf{Z}$ 为 5 个关键连续变量（*dist_center*、*Lat*、*Lng*、*ladderRatio*、*DOM*）组成的向量。经度和纬度参与扩展以捕捉空间曲面的弯曲，梯户比和挂牌天数参与扩展以允

许边际效应递减。 $trade_year$ 不再参与多项式扩展，因为时间固定效应已通过年度虚拟变量灵活捕捉了非线性的时间趋势。 $\mathbf{Z} \otimes \mathbf{Z}$ 包含所有二次项和两两交互项。

该设定允许关键变量存在非线性边际效应，但代价是引入严重的多重共线性（见第五章）。上述线性基准模型（带有时间-区域双向固定效应）是本文进行经济推断的主要依据，而多项式模型主要用于对比和展示非线性扩展的代价。

4.2 变量选择的共识策略

为在高维特征空间（64 个特征，含时间固定效应）中识别最重要的预测变量，本研究综合运用三种方法：基于 AIC 的向前选择、基于 AIC 的向后剔除，以及 LASSO 正则化路径。采用共识策略确定最终变量集，以增强变量选择的稳健性。

变量选择结果如下：全部 64 个特征中，29 个被三种方法一致选中，30 个被两种方法选中，4 个仅被一种方法选中，1 个未被任何方法选中。最终共识变量集包含 59 个变量。三种方法的一致性程度较高。被一致选中的重要变量包括经纬度、距市中心距离、梯户比、有无电梯、临近地铁、建筑面积对数及大部分区域虚拟变量。年份虚拟变量和多数月份虚拟变量同样被全票选中，验证了时间固定效应纳入模型的必要性。

4.2.1 LASSO 正则化与惩罚力度问题




图 5: LASSO 正则化路径

LASSO 交叉验证选择的最优惩罚参数为 $\alpha = 0.0001$ ，恰好位于搜索网格 $[10^{-4}, 10^0]$ 的下界。图 5 显示，模型在此参数下保留了 60/64 个非零系数，惩罚力度极为微弱。将搜索网格向下扩展至 10^{-5} 后，最优 α 仍然落在新的下界，表明这一结果并非网格设定问题所导致。

这一现象的数据解释是：64 个候选特征中绝大多数都与房价存在统计上显著的关联，强预测信号在特征空间中广泛分布，LASSO 无法通过 L1 惩罚将有效信号压缩为零。这与真实模型稀疏的隐含前提相悖，住房价格通常受众多微效因素共同影响。因此 LASSO 在本应用中本质上退化为了普通 OLS，这也解释了为何在后文的模型比较中二者的预测表现几乎完全一致。

5. 模型诊断

基于全变量 OLS 模型（子样本 20 000 行），对经典线性回归的假设条件进行系统检验。选择 20 000 行子样本出于两方面考虑：其一，`statsmodels` 的影响诊断（帽子矩阵、Cook's 距离等）在全样本（25 万行）上计算开销较大；其二，20 000 行样本的样本/特征比超过 300:1，在统计上已完全充分。

5.1 诊断检验结果

表 2: 模型诊断结果汇总

检验项目	结果
VIF > 10 变量数	9 个: buildingStructure 系列、square、log_square、trade_year_2016/2015/2017
最大 VIF（不含常数项）	492.4（buildingStructure_6）
条件数	4.59×10^5 （较原模型 7.84×10^6 大幅改善）
Breusch-Pagan 检验	LM=957.6, $p = 1.8 \times 10^{-159}$, 拒绝同方差
Goldfeld-Quandt 检验	$F = 0.979$, $p = 0.857$, 不拒绝同方差
Durbin-Watson 统计量	1.966, 无自相关
Cook's D 异常点比例	4.74%（947/20 000）超过阈值
HC3 下显著性改变量	1 个变量（fiveYearsProperty_1.0）




图 6: 方差膨胀因子（前 20 名变量，红色虚线为 VIF=10 阈值）

5.2 多重共线性讨论

表 2 报告了 VIF 诊断结果。*buildingStructure_6* 和 *buildingStructure_2* 存在严重的多重共线性。这与 *buildingStructure* 变量的类别分布密切相关：某些结构类别的占比极低，导致相应的虚拟变量与其他结构类别之间呈现近乎完全的线性关系。此外，*square* 和 *log_square* 之间的高度相关性也反映了面积变量在对数-线性变换后的共线性问题。部分年份虚拟变量的 VIF 超过 10，这是以 2011 年为高基期、多年度同时纳入模型时的自然结果。

对于以 OLS 为基础的统计论文，9 个 VIF 大于 10 的变量虽然不影响模型的整体预测能力，但会膨胀个体系数的标准误、降低估计精度。加入时间固定效应后条件数从 7.84×10^6 降至 4.59×10^5 ，这是因为原模型中的 *trade_year* 连续变量与其平方项之间存在大量共线性，被年份虚拟变量替代后这一来源得到消除。在 OLS 与多项式组合模型中，多重共线性问题因高阶项的加入而显著加剧，详见第 6.3 节。

5.3 异方差与残差分析

Breusch-Pagan 检验在 1% 水平上显著拒绝同方差假设，而 Goldfeld-Quandt 检验未能检测到异方差。两个检验结论的不一致根源在于检验功效和敏感性的差异：BP 检验对一般形式的异方差均敏感，而 GQ 检验仅对排序后单调变化的方差敏感。

残差诊断图显示，当拟合值增大时残差幅度呈现扩散趋势，这一漏斗状模式支持 BP 检验的结论，即样本中存在不可忽略的异方差。




图 7: 残差诊断图（第一行：残差 vs 拟合值、正态 Q-Q 图、尺度-位置图；第二行：残差分布、残差 vs 杠杆值、实际值 vs 预测值）

5.4 稳健标准误

采用 HC3 稳健标准误对 OLS 系数进行校正。结果表明校正后仅一个变量 *fiveYear-sProperty_1.0* 的显著性判断发生改变，从 $p = 0.048$ 变为 $p = 0.053$ ，略超 5% 阈值。这

一结果优于原模型，说明加入时间固定效应后异方差对推断的干扰进一步减弱。因此，HC3 稳健标准误的使用主要作为学术严谨性的必要组成部分，而非因为实质性改变了结论。

截面数据的异方差在真实世界中是常态而非异常。本研究从事前和事后两个层面确保了推断的可靠性。事前，半对数设定将绝对差异转化为相对差异，从数据变换的根源上缓解了方差随价格水平递增的趋势。事后，HC3 稳健协方差矩阵的修正进一步消除了异方差对标准误估计的干扰。因此，即便 Breusch-Pagan 检验明确拒绝了同方差假设，核心变量边际效应的推断结果仍然是稳健且可靠的。

5.5 DOM 缺失值处理的稳健性

DOM 缺失率达 50%，为检验其处理方式对核心结论的影响，本文比较了两种设定：包含 DOM 与 *DOM_missing*（基准）和完全剔除 DOM 及其指示变量。结果表明，剔除 DOM 后模型 R^2 从 0.8185 微降至 0.8175，核心变量系数的最大变化不足 1%：距市中心距离系数从 -2.689 变为 -2.698（差异 0.33%），梯户比系数从 0.168 变为 0.167（差异 0.42%）。此外，*DOM_missing* 的系数显著为负（-0.028, $p < 0.001$ ），表明 DOM 缺失的房源系统性地价格偏低，与非随机缺失的推论一致。上述结果证实，DOM 缺失值的处理方式未对核心变量的经济推断构成实质性威胁。

6. 模型比较与结果解释

本研究比较了六种回归模型在测试集上的表现：OLS 全变量模型、Ridge 回归、LASSO 回归、OLS 共识筛选变量模型、OLS 与交互项组合以及 OLS 与多项式组合。其中 *trade_year* 因转为虚拟变量不再参与多项式扩展。

6.1 预测表现比较

各模型在测试集上的表现汇总于表 3。

表 3: 测试集模型表现比较

模型	R^2	RMSE（元/m ² ）	MAE（元/m ² ）	AIC
OLS + 多项式	0.8294	9 411	6 471	-207 770
OLS + 交互项	0.8218	9 621	6 631	-205 038
OLS（全变量）	0.8185	9 696	6 703	-203 859
Ridge（CV）	0.8185	9 696	6 703	—
OLS（筛选变量）	0.8184	9 695	6 703	-203 867
LASSO（CV）	0.8180	9 710	6 713	—

OLS 与多项式组合模型在预测指标上表现最佳， $R^2 = 0.829$ ，RMSE 为 9 411 元/m²，

较基准 OLS 提升约 1.1 个百分点。五折交叉验证结果与测试集一致，排除了过拟合的可能。

基准 OLS 模型的 R^2 为 0.818，RMSE 为 9696 元/ m^2 ，表明时间固定效应设定能够有效捕捉房价的非线性时间趋势。OLS 与多项式模型之间的 R^2 差距为 1.1 个百分点，这一差距相对较小，说明时间固定效应已经捕捉了部分原本需要多项式项才能拟合的非线性特征。

6.2 核心变量的边际效应解释

在评估模型时，本研究不仅关注预测精度，更重视核心变量边际效应的经济学含义。以下基于共识变量 OLS 模型对关键变量进行半弹性解释。在对数-线性模型中，连续变量的系数 β 的精确解释为：该变量增加一个单位时，响应变量变化 $100 \times (e^\beta - 1)\%$ 。当系数绝对值较小时， $\beta \times 100\%$ 可作为近似。

首先考察空间因素的影响。距市中心距离的系数为 -2.681 ，意味着距天安门每增加 0.01 度，房价下降约 2.65%。以 2017 年北京二手房均价约 6 万元/ m^2 计算，每远离市中心 1 公里，单价下降约 1590 元。这一效应在统计和经济意义上均高度显著，支持了北京作为单中心城市的空间结构特征。

房屋建筑特征方面，有无电梯的系数为 0.074，有电梯的房源比无电梯房源价格高出约 7.7%。对于均价 6 万元/ m^2 的住宅，这一溢价约为 4620 元/ m^2 ，折合到一套 80 m^2 的住房约为 37 万元。梯户比的系数为 0.167，每增加 0.1，房价上升约 1.68%，反映了居住舒适度对房价的资本化效应。

交通便利性方面，临近地铁的系数为 0.056，临近地铁的房源溢价约为 5.8%，体现了轨道交通对住房价值的资本化效应。这一效应在远郊区域可能更为显著，因为远郊居民对轨道交通的依赖度高于中心城区。

图 8 展示了共识变量 OLS 模型中绝对值最大的 15 个系数。可以直观看出，距市中心距离 (*dist_center*) 的负向效应最为突出，经纬度和区域虚拟变量次之，表明空间因素是房价差异的核心驱动力。房屋属性中，电梯 (*elevator*) 和梯户比 (*ladderRatio*) 的正向效应相对显著。




图 8: 共识变量 OLS 模型系数图 (前 15 名)

图 9 为测试集上预测值与实际值的散点图。散点沿 45 度参考线紧密分布, $R^2 = 0.8184$, 表明模型整体拟合效果良好。但在高价区间 ($\log(\text{Price}) > 11.5$), 散点略向参考线下方偏离, 说明模型对极高端房产的预测略有低估。




图 9: 预测值 vs 实际值散点图 (共识变量 OLS, 测试集)

图 10 展示了 15 个区域的固定效应系数 (以 *district_1* 为基期)。系数正值越大表

示该区域相对于基期的溢价越高。东城区和西城区的系数最高，与中心城区房价领先的现实一致；房山区、平谷区等远郊区系数为负，反映了区位优势的价格折价。




图 10: 区域固定效应系数

6.3 多项式模型的系数膨胀问题

多项式扩展将 5 个关键变量 (*dist_center*、*Lat*、*Lng*、*ladderRatio*、*DOM*) 扩展为 20 个二次项和交互项，部分系数绝对值达到 200 至 800 的量级，在经济意义上不再具有合理的解释力。条件数对比进一步证实了这一问题：全变量 OLS 模型的条件数为 1.67×10^4 ，交互项模型升至 1.41×10^{16} ，多项式模型更高达 1.11×10^{12} ，远超严重多重共线性的经验阈值 (10^6)。

这一现象的根源在于多重共线性。区域虚拟变量 (*district_**) 本身就是地理空间的离散化表示，而经纬度的多项式组合是对同一空间的连续函数逼近。二者高度相关导致正规方程 ($\mathbf{X}'\mathbf{X}$) 近乎奇异，条件数急剧恶化，回归系数在理论上趋向无穷大，呈现出 ± 200 至 ± 800 的反常值。虽然 *trade_year* 已转为虚拟变量不再参与多项式扩展，但 *dist_center* 与 *Lat/Lng* 之间的空间共线性仍然足以引发矩阵病态。

这一发现揭示了一个重要的方法论教训：线性回归模型在引入高阶多项式项后，虽然预测精度有所提升，但其核心优势，即系数可直接解释为边际效应，受到了根本性损害。当研究目标是经济推断 (*inference*) 而非预测 (*prediction*) 时，简洁的主效应线性模型在设计合理的固定效应设定下，通常是更为可靠的选择。

6.4 时间趋势的进一步讨论

在共识变量 OLS 模型中，以 2011 年为基期，年份虚拟变量的系数呈现清晰的递增模式：*trade_year_2012* (+0.15)、*trade_year_2013* (+0.48)、*trade_year_2014* (+0.49)、*trade_year_2015* (+0.54)、*trade_year_2016* (+0.83) 和 *trade_year_2017* (+1.15)。这一序列的特征在于：2013 年较 2012 年有大幅跳跃 (+0.33)，而 2013-2015 年间增幅

相对平缓，年增约 0.03 至 0.05，2015 年后再次加速。该模式与探索性数据分析中观察到的「2011–2015 年初平缓上涨、2015 下半年后加速攀升」完全吻合。

若将 *trade_year* 作为连续线性变量（系数 0.180），等效于为所有年份施加了「年增幅约 19.7%」的单一系数，这必然低估 2015 年后的涨幅并高估 2011–2014 年的涨幅。时间固定效应通过年份虚拟变量解决了这一问题，避免了依赖 *trade_year*² 项来部分捕捉非线性趋势的妥协。月度虚拟变量的系数也从 2 月（+0.046）逐步递增至 12 月（+0.190），反映了一年内的季节价格上升趋势。

7. 结论

本研究在特征价格模型框架下，基于链家北京 2011–2017 年二手房交易数据，系统比较了六种回归模型的表现。主要发现如下。

空间因素是房价差异的主导变量。距市中心每增加 1 公里，房价下降约 2.7%，呈现显著的单中心城市空间衰减格局。时间因素具有非线性影响，年份虚拟变量系数从 2012 年的 +0.15 递增至 2017 年的 +1.15，验证了 2015 年前后的结构性加速。房屋特征方面，电梯（+7.7%）、地铁（+5.8%）、梯户比等边际效应在统计和经济意义上均高度显著。

在模型比较层面，多项式模型预测精度最高（ $R^2 = 0.829$ ），但高阶项导致系数膨胀至无法经济解释的程度。纳入时间和区域双向固定效应的线性主效应模型（ $R^2 = 0.818$ ）在可解释性与精度之间取得了更好的平衡。LASSO 因多数特征与房价存在真实关联而退化为 OLS。HC3 稳健标准误的采用仅改变了一个变量的显著性判断，推断结果整体稳健。

本研究存在若干局限。数据仅来源于链家平台，可能存在选择偏误。*DOM* 变量 50% 的缺失率可能引入填充偏倚。模型未纳入学区等遗漏变量，且未处理空间自相关和内生性问题，结果应解释为条件相关性而非因果关系。关于空间自相关，若邻近房源的误差项存在空间聚类，OLS 估计量仍保持一致性，但标准误可能偏小，导致显著性检验过于宽松。然而，本文核心变量的系数方向和经济显著性均很强（如距市中心距离每公里约 -2.7%），空间依赖不太可能逆转主要结论的方向。后续研究可考虑空间计量模型、工具变量法及 *buildingStructure* 类别合并等改进方向。

参考文献

- [1] Rosen S. Hedonic prices and implicit markets: product differentiation in pure competition[J]. Journal of Political Economy, 1974, 82(1): 34–55.
- [2] Lancaster K J. A new approach to consumer theory[J]. Journal of Political Economy, 1966, 74(2): 132–157.
- [3] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society: Series B, 1996, 58(1): 267–288.
- [4] Breusch T S, Pagan A R. A simple test for heteroscedasticity and random coefficient variation[J]. Econometrica, 1979, 47(5): 1287–1294.
- [5] White H. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity[J]. Econometrica, 1980, 48(4): 817–838.
- [6] Sirmans S G, Macpherson D A, Zietz E N. The composition of hedonic pricing models[J]. Journal of Real Estate Literature, 2005, 13(1): 1–44.
- [7] 郑思齐, 刘洪玉. 住房需求的收入弹性: 模型、估计与预测 [J]. 土木工程学报, 2005, 38(4): 85–89.